

{dev/talles}

Costos sin contexto

Por: Ricardo Cuellar





El problema con números

Ventana de contexto (gpt-4o-mini): 128,000 tokens

Documentos empresarial: ~10,000 tokens

Conversación larga: ~5,000 tokens

PDF técnico (50 páginas aprox.): ~40,000 tokens

Contrato legal: ~30,000 tokens



El problema con números (2)

Todo eso en un contexto:

$10,000 + 5,000 + 40,000 + 30,000 = 85,000$ tokens

Costo por llamada (gpt-4o-mini):

$85,000 * \$0.15 = \0.01275 por pregunta

¿Si hace 100 preguntas? Sería un costo total de

\$1.27 USD



¿Y el problema?

Esos \$1.27 USD solo son de tokens de entrada.

El modelo que usamos es un modelo barato, si lo cambiamos elevamos costos considerablemente.

Con RAG solo enviamos fragmentos relevantes donde se podría optimizar el uso de tokens y gastar aproximadamente ~40x veces menos.



Gracias



www.devtalles.com



[/ricardocuellar](https://www.linkedin.com/company/ricardocuellar)



[@DevTalles](https://twitter.com/DevTalles)