

{dev/talles}

RAG (Retrieval Augmented Generation)

Por: Ricardo Cuellar



¿Qué es el RAG?

Es una técnica que combina la generación de texto de un LLM con la recuperación de información de una base de datos o un conjunto de documentos específicos y generar una respuesta usando esa información como *contexto*.



¿Qué significa RAG?

R - Retrieval (Recuperación)

Busca y trae información relevante de una fuente externa.

A - Augmented (Aumentado)

El contexto del modelo se enriquece con esa información recuperada.

G - Generation (Generación)

Genera una respuesta en lenguaje natural usando tanto el conocimiento previo así como fragmentos recuperados del contexto.




¿Qué resuelve RAG?

Cuando no usamos RAG, los modelos de lenguaje tienen los siguientes problemas:

1. Fecha de corte: Solo saben lo que existía cuando fueron entrenados.
2. Alucinaciones: Inventan respuestas.

RAG resuelve ambos problemas porque se basa en documentos reales y actualizados, por nosotros en mayoría.

Flujo RAG



{dev/talles}

Indexing


Documentos



Chunks



Modelo de
Embeddings



Base de datos
Vectorial



Embeddings

Es la representación numerica de información (textos, imágenes, etc)


Capturan la relación semántica entre los elementos.

Presidente



0.95
0.90
0.80
0.10
0.00

Embeddings





Embeddings

Presidente

0.95
0.90
0.80
0.10
0.00

Hombre

0.10
0.95
0.90
0.20
0.00

Mujer

0.10
0.95
0.00
0.90
0.00

Presidenta

0.95
0.90
-0.10
0.80
0.00

$$\text{Presidente} - \text{Hombre} + \text{Mujer} = \text{Presidenta}$$

{dev/talles}




Retrieval


Base de datos
Vectorial



Chunk más
relevante



Query






Generation

Contesta lo siguiente: Prompt

Con base a esta información: Chunk elegido

Generation





Gracias



www.devtalles.com



[/ricardocuellar](https://www.linkedin.com/company/ricardocuellar)



[@DevTalles](https://twitter.com/DevTalles)