

{dev/talles}

Memoria persistente

Por: Ricardo Cuellar



¿Qué es la memoria de contexto?

Es dónde y cómo guardamos el historial de mensajes entre llamadas a la API.
El LLM no tiene estado. No recuerda nada entre llamadas.



¿Entonces quién hace ese trabajo?



Nosotros, somos quienes debemos persistir ese historial y enviarlo en cada nueva llamada.

Tipos de memoria

Vamos a definir 4 tipos de memoria:

- RAM
- DISCO
- Base de datos.
- Base de datos en memoria.




IN-MEMORY (RAM)

Se Almacena: Variables Python

Ventajas: Instantánea, sin configuraciones

Desventajas: Se pierde al cerrar o terminar el programa

Usos: Prototipado, test





SQLITE

Se Almacena: Archivo .db en disco local

Ventajas: Persiste, no necesita servidor.

Desventajas: Un proceso a la vez y no es distribuida

Usos: Apps locales, proyectos personales, desarrollo





POSTGRESQL

Se Almacena: Servidor de base de datos

Ventajas: Múltiples usuarios, escalable, usada para producción

Desventajas: Requiere configuración del servidor y conocimientos en bases de datos.

Usos: Producción, APIs con múltiples usuarios, multiples consultas





REDIS

Se Almacena: Servidor en memoria con persistencia

Ventajas: Muy rápida para sesiones activas

Desventajas: Requiere un servidor Redis

Usos: Sesiones de alta frecuencia, cache





session_id

Es el identificador único de cada conversación. Permite que el mismo sistema sirva múltiples usuarios con historiales separados.





MessagesPlaceholder

Es el componente de LangChain que le dice al prompt: “En este punto, inserta automáticamente todos los mensajes anteriores de esta sesión”. LangChain los carga desde la base de datos antes de cada llamada LLM.





RunnableWithMessageHistory

Es el wrapper que conecta una cadena con un backend de memoria. Hace tres cosas automáticamente:

1. Antes de invocar: Carga el historial de la Base de datos usando el `session_id`.
2. Inyecta ese historial en el `MessagesPlaceholder` del prompt
3. Después de invocar: guarda el nuevo mensaje en la DB





Gracias



www.devtalles.com



[/ricardocuellar](https://www.linkedin.com/company/ricardocuellar)



[@DevTalles](https://twitter.com/DevTalles)